

Estudio de la eficiencia técnica y operativa en la infraestructura de carga de vehículos eléctricos a través de la simulación de eventos discretos en la Ciudad Autónoma de Buenos Aires

Carlana Rivero, Agustín

Loglen, Luca

Millan, Juan Ignacio

Ojeda, Daniel

Universidad Tecnológica Nacional, Facultad Regional Buenos Aires

Abstract

This paper develops a discrete-event simulation model to determine an efficient number of charging spots for electric vehicles in the Ciudad Autónoma de Buenos Aires (CABA). The system was modeled under a multi-queue, multi-server configuration, and it was implemented in Python. Historical data was processed to fit the probability density functions of the system's stochastic variables. Due to the lack of massive local empirical records, the simulation is fed by public datasets from charging stations in California. Through goodness-of-fit analysis, a Landau distribution was determined for the Interarrival Times and a Gumbel R distribution for the Charging Time. Since costs depend on Charging Time, linear regression was used to model the relationship between the two variables. The simulation of multiple operational scenarios revealed a critical relationship between capacity and performance. Results indicate that current real-world configurations of 4 to 5 distributed points suffer from critical congestion, generating excessive wait times of 78 to 85 minutes and a massive user abandonment rate between 53% and 60%. Conversely, operating with an oversized network of 20 or more charging points leads to an inefficient use of resources, with idle times consistently exceeding 66%. The study concludes that an optimal technical and operational balance is achieved with a distributed network of 14 to 16 independent charging points. This configuration successfully captures demand, reducing abandonment to 15%-19%, while maintaining the structural idle capacity (56%-62%) strictly necessary to absorb stochastic demand peaks without allowing queues to grow infinitely.

Palabras Clave

Simulación de eventos discretos, vehículos eléctricos, teoría de colas, estaciones de carga, tiempo de espera, funciones de densidad de probabilidad, CABA.

1. Introducción

El crecimiento sostenido de la movilidad eléctrica plantea el desafío estratégico de dimensionar adecuadamente la infraestructura de carga. El problema central radica en encontrar un equilibrio técnico y operativo, una cantidad insuficiente de puestos de carga genera congestión, tiempos de espera excesivos y una alta tasa de abandono por parte de los usuarios, mientras que un sobredimensionamiento deriva en recursos inactivos y un gasto de capital ineficiente.

El objetivo principal de esta investigación es construir un modelo computacional para evaluar múltiples escenarios operativos, iterando la cantidad de puestos de carga (N) desde configuraciones mínimas hasta redes expansivas. Para ello, creamos un notebook de *Python* en la plataforma de *Google Colab* [1]. Este, mediante el uso de bibliotecas como *Numpy*, *Scipy* y *Fitter*, extrae datos de un dataset, los procesa, les realiza ajustes de funciones de densidad de probabilidad, les aplica regresión lineal, y los utiliza para ejecutar la lógica de la simulación.

De este modo, se busca identificar la configuración óptima que logre contener el porcentaje de arrepentimiento (PARR) y el tiempo promedio de espera en cola (PEC), garantizando al mismo tiempo un porcentaje de tiempo ocioso (PTO)

razonable que justifique la infraestructura instalada.

2. Metodología

2.1. Descripción del sistema

Dado que este tipo de sistemas presenta un comportamiento dinámico y aleatorio, producto de la variabilidad en las llegadas de vehículos y los tiempos de carga, la simulación de eventos discretos se presenta como una herramienta adecuada para su análisis. Esta permite modelar el sistema bajo distintas configuraciones y evaluar su desempeño sin necesidad de intervenir en la realidad.

El sistema puede describirse como un modelo de múltiples colas y múltiples servidores (n colas, n servidores), donde:

- Los vehículos representan las entidades del sistema.
- Cada puesto de carga representa un servidor independiente.
- Cada puesto posee su propia cola asociada.
- Los vehículos se asignan aleatoriamente a cualquiera de los puestos (se distribuye uniformemente la demanda).
- Un vehículo puede **arrepentirse** de acceder a un puesto dependiendo de la cantidad de vehículos que están presentes en dicho puesto.

Este modelo contempla el arrepentimiento de un vehículo al intentar ingresar al sistema: cuando un potencial ingresante se arrepiente, no se contabiliza su incorporación al sistema, registrándose en cambio como un evento de abandono.

Para determinar la probabilidad de abandono en función de la ocupación del puesto, se recurrió a un estudio sobre la impaciencia de usuarios en estaciones de

carga [2]. A partir de la Figura 1, que presenta el porcentaje de abandono bajo distintos escenarios de información y tasas de llegada, se tomó como referencia el valor de convergencia de la curva ObservationFC con $\lambda=0.6$, ya que dicha distribución aproximaba los arribos de vehículos eléctricos en horas pico, para definir las siguientes reglas:

- Si un vehículo llega y el puesto está libre, se incorpora al sistema.
- Si un vehículo llega y hay 1 vehículo en el puesto, la probabilidad de abandono es del 93%.
- Si un vehículo llega y hay 2 o más vehículos en el puesto, se asume abandono con probabilidad del 100%.




Figura 1. Porcentajes de arrepentimiento simulados según distintas distribuciones.

2.2. Análisis Previo

Antes de empezar con el proceso de simulación, debemos realizar el análisis del contexto de aplicación. Para ello debemos realizar 3 pasos: **Definición de Metodología, Clasificación de Variables y Definición de Eventos.**

2.2.1 Metodología de Simulación

Como se mencionó anteriormente, la metodología elegida para este caso será la **Metodología Evento a Evento**.

La metodología de Evento a Evento describe un algoritmo para poder efectuar el modelo. Los pasos son los siguientes:

- Fijación de las condiciones iniciales.
- Determinación del instante en que ocurrirá el próximo evento.
- Avance del tiempo hasta ese instante.
- Determinación del tipo de evento que sucede en dicho instante.
- Determinación del instante en que ocurrirán eventos futuros no condicionados consecuencia del evento actual.
- Actualización del vector de estado del modelo.
- Determinación del instante en que ocurrirán eventos futuros condicionados consecuencia del evento actual.

Una vez que se alcanza el último paso el algoritmo de la metodología va a iterar a partir del segundo paso si es que no finaliza la simulación.

Durante la ejecución de este algoritmo debe accederse a la Tabla de Eventos Futuros para determinar el instante de próximos eventos o bien para actualizar las variables de dicha tabla.

Una vez que se alcanza el fin de la simulación lo último que queda es calcular y posteriormente mostrar los resultados, para ahora sí finalizar la simulación.

2.2.2. Clasificación de variables

- **Variables Exógenas:** Son independientes del sistema, la entrada al modelo. Actual sobre el

sistema y no son modificadas por este.

- o **Variables de Datos:** Valores tomados de la realidad que son imposibles de modificar.
 - Intervalo de Arribos de vehículos (**IA**)
 - Tiempo de Carga (**TC**)
- o **Variables de Control:** Son instrumentales, pueden ser controlables. Se establecen según una estrategia para barrer la superficie de resultados.
 - Cantidad de Puestos de Carga (**N**)
- **Variables Endógenas:** Son las variables dependientes del sistema, varían durante las corridas.
 - o **Variables de Estado:** Describen el estado del sistema o de uno de sus componentes durante cierto instante. El vector de estado refleja los cambios en el sistema, dado por la aparición de eventos.
 - Cantidad de Vehículos en el sistema por Puesto (**NS(i)**)
 - o **Variables de Resultado:** Son las salidas del sistema, se generan por la interacción de las variables exógenas y de las variables de estado.
 - Promedio de Espera en Cola (**PEC**)
 - Promedio de Permanencia en el Sistema (**PPS**)

- Porcentaje de Tiempo Ocioso de un cargador (PTO(i))
- Porcentaje de Arrepentimientos (PARR)
- Costo de Consumo Energético (CCE)

2.2.3. Definición de eventos

Se define un evento como un hecho o acontecimiento que se produce en el sistema. Bajo este concepto, podemos identificar los siguientes eventos:

- **Llegada:** Ocurre cuando un nuevo vehículo arriba a un puesto de carga. Puede generar el inicio inmediato de carga si hay disponibilidad o su ingreso a la cola del puesto en cuestión en caso contrario.
- **Salida:** Ocurre cuando un vehículo finaliza su proceso de carga y libera un puesto, permitiendo que otro vehículo comience a ser atendido, en caso de que haya uno esperando en cola.

Los eventos de Llegada son **independientes** de los eventos de Salida, ya que una Salida de cualquiera de los puestos está sujeta a una **condición** para que ocurra luego de una Llegada. Esta distinción es necesaria al momento de efectuar la **Tabla de Eventos Independientes** (T.E.I.), que presenta tres simples reglas:

1. Está conformada por tantas filas como eventos independientes tenga el modelo.
2. En la tabla solo pueden escribirse eventos independientes.

3. Por tratarse de eventos independientes, en la columna de Evento Futuro no Condicionado (E.F. NO C., segunda columna) debe **escribirse el mismo evento de la fila que le dio origen o nada**. Esto se debe a que, por tratarse de eventos independientes, un evento no puede generar (sin que medie condición alguna) otro evento distinto de sí mismo.
4. La columna de Condición es un anexo a la tabla, no pertenece a esta realmente. En ella debe expresarse la **condición que encadena eventos**, por lo tanto, las variables que allí aparecen sólo pueden ser variables de estado. También, se pueden escribir valores fijos o que permanezcan constantes a lo largo de la corrida (variables de control).

Por otro lado está la **Tabla de Eventos Futuros** (T.E.F.), formada por los instantes de tiempo en el que se producirá un tipo de evento. Es posible completar dicha tabla en paralelo con la Tabla de Eventos Independientes (T.E.I.).

Con estas reglas y con los eventos definidos anteriormente completamos las tablas de la siguiente manera:

- A partir de una Llegada y gracias a mi dato de Intervalo de Arribos puedo determinar en qué momento exacto se va a producir otra llegada, es decir que una Llegada es un Evento Futuro no Condicionado por sí misma. Además de que luego de una Llegada podemos determinar el Tiempo de Próxima Llegada, variable que guardamos en la Tabla de Eventos Futuros.
- Una Salida se produce siempre y cuando haya gente en un puesto. La única manera de saber cuando voy

a salir del sistema es cuando estoy siendo atendido en un puesto.

- Si al llegar a un puesto de carga soy el único presente, soy capaz de saber cuando voy a salir del sistema gracias al dato del tiempo de carga. Así podemos identificar una nueva variable de la Tabla de Eventos Futuros, el Tiempo de Próxima Salida. Como esta variable va a depender del puesto será un vector con tantas entradas como puestos de carga tenga el sistema.
- Cuando se produce una Salida se desocupa uno de los puestos y el siguiente elemento del sistema accede al mismo, pudiendo en este instante determinar su Tiempo de Próxima Salida en dicho puesto. Sin embargo, si ya no quedan elementos en la cola no puedo determinar la próxima salida que ocurra del puesto.

Evento	E. F. No C.	E. F. C.	Condición
Llegada	Llegada	Salida[i]	NS[i]=1
Salida[i]	-	Salida[i]	NS[i]>0

Tabla 1. Tabla de Eventos Independientes del sistema

T.E.F.	Tiempo de Próxima Llegada - TPLL	Tiempo de Próxima Salida - TPS[i]
--------	----------------------------------	-----------------------------------

Tabla 2. Tabla de Eventos Futuros del sistema

Cabe aclarar que para simplicidad las Salidas se representan como vector, ya que hay tantos eventos de salida como puestos haya en la simulación.

2.3. Obtención de Datos

Para parametrizar el modelo de simulación fue necesario estimar las dos variables aleatorias de datos del sistema: el Intervalo entre Arribos (IA) y el Tiempo de Carga (TC).

Ambas variables presentan comportamiento estocástico por lo que su representación dentro del modelo requiere la identificación previa de sus respectivas funciones de densidad de probabilidad (F.D.P.).

Ante la ausencia de registros empíricos de estaciones de carga de vehículos eléctricos en Argentina o en CABA no resultó posible obtener directamente estas distribuciones a partir de datos locales. Por ello, se recurrió a un dataset público de estaciones de carga de California [3]. En consecuencia, las F.D.P. obtenidas deben interpretarse como una aproximación razonable para modelar el comportamiento estocástico del sistema, y no como una representación precisa de los tiempos de carga o la demanda real en CABA.

En caso de disponer de datos específicos de CABA, la metodología utilizada permitiría calcular la F.D.P. del intervalo entre arribos a partir del nuevo dataset, manteniendo inalterada la estructura de la simulación. De esta manera, el modelo conservaría su funcionamiento general, ajustándose únicamente los parámetros estadísticos asociados al intervalo de arribos para representar con mayor precisión el contexto local.

2.3.1. Obtención de la Función de Densidad de Probabilidad (F.D.P) del Tiempo de Carga (TC)

A partir del conjunto de datos del Tiempo de Carga, se observó una distribución con una cola derecha pronunciada, lo que indica un comportamiento asimétrico con sesiones de carga de larga duración poco frecuentes pero presentes.




Figura 2. Histograma de Tiempos de Carga del dataset

Debido a este comportamiento, el criterio que se usó a la hora de buscar qué distribuciones se ajustaban mejor a los datos fue el de menor estadístico de Kolmogorov-Smirnov (KS).




Figura 3. Mejores distribuciones para el Tiempo de Carga según KS

Entre las cinco funciones de menor KS, la distribución seleccionada fue la **Gumbel R**. Esto porque no solo presentó el menor valor de KS, si no que también es la que presentó menor error cuadrático medio

(*sumsquare_error*) y menor divergencia de Kullback-Leibler (*kl_div*) de las cinco, lo que constituye una evidencia sólida de su adecuación para representar el fenómeno.




Figura 4. Función de Densidad de Probabilidad de Tiempo de Carga por distribución Gumbel R

Formalmente, si denotamos por TC a la variable aleatoria tiempo de carga, su Función de Densidad de Probabilidad (FDP) fue modelada como:

$$TC \sim \text{Gumbel}(\mu_{TC}, \beta_{TC})$$

donde μ_{TC} y β_{TC} representan los parámetros estimados a partir del ajuste de la distribución sobre los datos observados.

2.3.2. Obtención de la Función de Densidad de Probabilidad (F.D.P) del Intervalo entre Arribos (IA)

A partir del conjunto de datos del Intervalo entre Arribos se observó igualmente una distribución con una cola derecha pronunciada, lo que indica un comportamiento fuertemente asimétrico y con eventos de baja frecuencia pero alta magnitud (intervalos largos entre llegadas consecutivas).




Figura 5. Histograma de Intervalos de Arribos del dataset

Al igual que antes, el criterio que se usó a la hora de buscar qué distribuciones se ajustaban mejor a los datos fue el de menor *KS*.




Figura 6. Mejores distribuciones para el Intervalo de Arribos según *KS*

En este proceso, la distribución seleccionada fue la **Landau**, dado que si bien no presentó el menor valor de *KS* entre los candidatos, sí obtuvo los mejores resultados en *sumsquare_error* y *kl_div*, lo que refleja un mejor ajuste global a la forma de la distribución. El análisis conjunto de estos tres indicadores es el criterio más robusto frente a distribuciones con colas pesadas, donde el *KS* puede resultar insensible a discrepancias en las regiones extremas.




Figura 7. Función de Densidad de Probabilidad de Intervalo de Arribos por distribución Landau

Formalmente, si denotamos por IA a la variable aleatoria Intervalo de Arribos, su Función de Densidad de Probabilidad (FDP) fue modelada como:

$$IA \sim \text{Landau}(\mu_{IA}, \beta_{IA})$$

donde μ_{IA} y β_{IA} representan los parámetros estimados a partir del ajuste de la distribución sobre los datos observados.

2.4. Cálculo de Costos

Para poder obtener el Costo de Consumo Energético por puesto en la Simulación, hace falta calcular el Costo Energético de cada carga. Y este no es un dato independiente: está ligado al Tiempo de Carga actual y al Precio de la Energía. Es por esto que hace falta hallar una función que nos permita pasar de Tiempo de Carga a Costo Energético.

2.4.1. Obtención del valor del Precio de Energía (PE)

El Precio de Energía se modela como una variable determinística constante, representativa del costo medio de la energía eléctrica consumida por los

cargadores. Para su determinación se utilizó como fuente el cuadro tarifario vigente de Edenor [4]. Dentro de las distintas categorías tarifarias disponibles, se seleccionó la correspondiente a “**T3 - Grandes Demandas**”, dado que la potencia demandada por los cargadores considerados en el modelo puede superar los 50 kW [5], umbral a partir del cual se encuadran en dicha categoría.

Asimismo, se adoptó la clasificación de **Baja Tensión**, en concordancia con el tipo de conexión eléctrica típicamente utilizada por este tipo de infraestructura. En cuanto al nivel de potencia contratada, se consideró el rango **menor a 300 kW**, hipótesis que resulta consistente con escenarios de operación realistas del sistema analizado y cuya validez se sustenta en la Figura 8, donde el nivel de potencia alcanza los 300 kW recién casi a los 70 puestos.




Figura 8. Relación entre Potencia Promedio y Cantidad de Puestos

A partir de esta segmentación, se obtuvieron los valores del costo de la energía expresados en \$/kWh para las distintas franjas horarias definidas en el esquema tarifario. Finalmente, y con el objetivo de simplificar su incorporación al modelo, se calculó un valor promedio ponderado asumiendo una utilización uniforme a lo largo del día, el cual se

adopta como precio constante de la energía en la simulación.

2.4.2. Obtención de la función para el Costo de Energía (CE)

El Costo Energético se modela como una variable determinística dependiente del proceso de carga, calculada a partir de la energía consumida en cada sesión.

En primer lugar, se analizó la relación entre el tiempo de carga y la energía consumida por carga [3], observándose un comportamiento aproximadamente lineal entre ambas variables que se ve reflejado en la Figura 9. En función de ello, se optó por ajustar un modelo de regresión lineal que permita estimar la energía consumida en función del tiempo de carga.




Figura 9. Gráficos de tiempos de carga y de energía consumida en la carga

El ajuste realizado presentó un coeficiente de determinación elevado ($R^2 = 98\%$), que indica una fuerte correlación lineal y valida la hipótesis adoptada. De este modo, se obtuvo una función lineal que, dado un tiempo de carga, permite estimar la energía consumida asociada a dicho proceso.

Finalmente, el Costo Energético se calcula como el producto entre la energía estimada y el Precio de Energía definido previamente. De esta manera, se incorpora al modelo una representación consistente

del costo asociado a cada evento de carga, en función de su duración.

3. Resultados

Se evaluaron los resultados de la simulación variando la cantidad de puestos de carga disponibles en función de distintos escenarios:

- **Escenario 1:** configuración real
- **Escenario 2:** incremento de puestos (escenario eficiente)
- **Escenario 3:** reducción de puestos o sobre-incremento de puestos (escenario ineficiente)

3.1. Escenario Real

En este escenario se evalúa el comportamiento del sistema bajo la configuración real que tienen muchas empresas hoy en día, que está entre $N = 4$ y $N = 5$. Este caso se adopta como escenario de referencia para comparar el desempeño operativo y energético frente a configuraciones más eficientes o deficitarias.

Los resultados de la simulación demuestran que el sistema se encuentra fuertemente congestionado ante la tasa de arribos de la demanda proyectada. El tiempo promedio de espera en cola (PEC) alcanza valores situados entre los 78 minutos y los 85 minutos. Esta alta congestión dispara la tasa de abandono de los usuarios, reflejando un porcentaje de arrepentimiento (PARR) entre el 53% y el 60%. Si bien los recursos físicos operan a gran capacidad (con un porcentaje de tiempo ocioso, PTO, situado entre el 26% y el 30%), la calidad del servicio es deficiente, demostrando que esta configuración es insuficiente para sostener el parque automotor.




Figura 10. Comparación de Porcentaje de Tiempo Ocioso por cargador para 5 cargadores

Desde el punto de vista energético, el Costo de Consumo Energético (CCE) total se mantiene prácticamente constante entre configuraciones, tomando valores comprendidos entre \$93.600 y \$93.900. En contraste, el Costo de Consumo Energético Promedio presenta una tendencia decreciente a medida que aumenta la cantidad de cargadores N , variando entre aproximadamente \$23.400 y \$18.800. Este comportamiento se explica por la distribución de la demanda entre una mayor cantidad de recursos, reduciendo el consumo promedio asociado a cada cargador.

3.2. Escenario Eficiente

Este escenario busca encontrar la cantidad óptima de puestos que garantice una buena calidad de servicio sin incurrir en gastos desmedidos. De acuerdo con el análisis, el punto de equilibrio operativo se alcanza con una configuración de entre $N = 14$ y $N = 16$ puestos de carga. Al incrementar la capacidad a esta franja, el desempeño del sistema mejora drásticamente. El tiempo de espera (PEC) se reduce a niveles entre 39 y 43 minutos promedio. Como consecuencia directa, el porcentaje de arrepentimiento (PARR) se desploma, ubicándose en valores manejables (entre

15% y 19%), lo que asegura que la gran mayoría de la demanda sea captada. El tiempo ocioso (PTO) se eleva a un rango del 56% al 62%; aunque parece elevado, en la teoría de colas con llegadas y atenciones estocásticas, este margen de holgura es estrictamente necesario para absorber los picos de demanda sin que las colas tiendan al infinito.




Figura 11. Comparación de Porcentaje de Tiempo Ocioso por cargador para 15 cargadores

En términos energéticos, el Costo de Consumo Energético (CCE) total permanece prácticamente constante respecto de otros escenarios, tomando valores cercanos a los \$94.000 para todas las configuraciones analizadas. Por otro lado, el CCE Promedio disminuye progresivamente a medida que aumenta la cantidad de puestos de carga, pasando de \$6.700 para N=14 hasta \$5.878 para N=16, respectivamente. Esto evidencia una distribución más eficiente de la demanda entre los recursos disponibles, sin generar incrementos significativos en el consumo energético total del sistema.

3.3. Escenarios No Eficientes

En estos escenarios se analiza el impacto de una sobreinversión en la infraestructura, incrementando la cantidad de cargadores a valores de $N \geq 20$; y el impacto de la

reducción de cantidad de cargadores a valores de $N \leq 6$.

En la sobreinversión, si bien los indicadores orientados al usuario alcanzan niveles excelentes (el PEC cae por debajo de los 33 minutos y el Porcentaje de Arrepentimiento (PARR) es menor al 12%), la eficiencia desde el punto de vista del uso de los recursos colapsa. Por otro lado, el Costo de Consumo Energético (CCE) total permanece prácticamente constante, manteniéndose cercano a los \$94.000 aun cuando aumenta la cantidad de cargadores instalados. Sin embargo, el CCE Promedio continúa disminuyendo, alcanzando valores inferiores a los \$4.700 y reduciéndose aproximadamente entre \$100 y \$200 adicionales por cada nuevo puesto incorporado. Esto evidencia que el incremento de infraestructura no produce mejoras proporcionales en el desempeño global del sistema, generando recursos subutilizados y capital inmovilizado durante gran parte de la jornada operativa.

N (puestos)	PPS	PEC	PTO Promedio	CCE Total	PARR
20	153,91	32,91	66,80%	\$ 93.670,04	11,27%
21	152,48	31,69	68,71%	\$ 93.468,15	10,19%
22	152,94	31,29	69,18%	\$ 94.272,12	9,98%
23	151,07	29,80	69,95%	\$ 93.928,94	9,18%
24	150,74	29,12	71,51%	\$ 94.254,85	8,63%

Figura 12. Comparación de resultados para más de 20 cargadores

En cuanto a la reducción de cargadores, como ya hablamos en el caso real, habría una saturación en el sistema. Esto generaría esperas largas (el PEC se podría elevar hasta 136 minutos), y gran pérdida de potenciales clientes (el Porcentaje de Arrepentimiento (PARR) podría aumentar hasta 88%). En términos energéticos, el CCE total disminuye levemente, variando entre aproximadamente \$93.300 para 6 puestos y \$93.000 para un solo puesto. No obstante, el CCE Promedio aumenta

considerablemente a medida que disminuye la cantidad de puestos, pasando de aproximadamente \$1.550 para 6 puestos hasta valores cercanos a \$93.000 para uno solo, como consecuencia de la elevada concentración de demanda sobre una infraestructura insuficiente.

N (puestos)	PPS	PEC	PTO Promedio	CCE Total	PARR
1	256,54	136,22	13,99%	\$ 93.029,88	88,67%
2	234,14	112,04	17,88%	\$ 94.695,75	78,30%
3	217,78	96,22	21,78%	\$ 94.188,06	68,77%
4	206,37	85,39	26,57%	\$ 93.654,93	60,01%
5	199,10	77,83	28,81%	\$ 93.921,40	52,55%
6	191,39	70,78	33,32%	\$ 93.305,00	46,61%

Figura 13. Comparación de resultados para menos de 6 cargadores

Por estas razones, tanto la sobreinversión como la subdimensionamiento de la infraestructura se consideran configuraciones no eficientes. Asimismo, el escenario real analizado previamente puede interpretarse como parte de este conjunto, dado que presenta síntomas de saturación similares a los observados en las configuraciones con baja cantidad de cargadores.

4. Discusión

Los resultados obtenidos evidencian el clásico conflicto inherente a la teoría de colas: el balance entre el nivel de servicio y la subutilización de capital. El análisis de sensibilidad demuestra que una red distribuida de entre 14 y 16 puestos independientes representa la verdadera frontera de eficiencia técnica y operativa.

Esta escala óptima permite maximizar la captación de la demanda, reduciendo el arrepentimiento de los usuarios (PARR) a valores de entre el 15.5% y el 19.1%, y normalizando los tiempos de espera promedio en cola (PEC) a una franja tolerable de 38 a 43 minutos. Los resultados evidencian que las instalaciones actuales son ineficientes por defecto: generan esperas excesivas (77 a 85

minutos) y disparan el abandono de usuarios a niveles insostenibles del 52% al 60%, a pesar de mantener una ociosidad aparente baja (<34%).




Figura 14. Comparación de Porcentaje de Arrepentidos




Figura 15. Comparación de Promedio de Espera en Cola en minutos

Sin embargo, la implementación real de este "escenario eficiente" en la Ciudad Autónoma de Buenos Aires debe contemplar restricciones exógenas al modelo. Al requerir el despliegue de una red de múltiples puestos independientes en lugar de una única locación centralizada, la planificación se enfrenta a diversos desafíos logísticos. Esto implica lidiar con limitaciones de espacio físico en múltiples nodos urbanos y asegurar que la capacidad de potencia de la red eléctrica barrial pueda soportar la nueva infraestructura en distintos puntos de la ciudad.

Asimismo, desde la perspectiva del modelo de negocio, asumir un tiempo ocioso estructural (PTO) de entre el 58% y el 61%, aunque matemáticamente

necesario para absorber la variabilidad estocástica de los arribos y reducir el arrepentimiento a valores manejables, representa un gran desafío para el retorno de inversión del operador comercial.

Por otro lado, superar este umbral hacia un sobredimensionamiento ($N \geq 20$ puestos) resultaría en un uso ineficiente del capital; aunque el arrepentimiento caiga por debajo del 12%, el tiempo ocioso escala por encima del 65%, inmovilizando activos sin una mejora que justifique la inversión.




Figura 16. Comparación de Porcentaje Promedio de Tiempo Ocioso

5. Conclusión

El modelo de simulación de eventos discretos desarrollado ha demostrado ser una herramienta robusta y de alta fidelidad para representar el comportamiento estocástico de una infraestructura de carga de vehículos eléctricos. Si bien el motor de la simulación se nutrió de datasets provenientes de estaciones de carga en California, la arquitectura del modelo permite una extrapolación técnica precisa y una adaptación fluida a la dinámica urbana de la Ciudad Autónoma de Buenos Aires. Esta aproximación no solo permite evaluar el impacto de la infraestructura actual, sino que redefine por completo los parámetros de eficiencia necesarios para el despliegue de autos eléctricos en la región.

A partir del análisis de sensibilidad realizado, se concluye que la configuración del caso real observado actualmente (4 a 5

puestos) y los escenarios mínimos (1 a 6 puestos) representan un estado de saturación crítica. En contraposición, el verdadero punto de equilibrio técnico-operativo para CABA se ubica en un escenario eficiente delimitado entre los 14 y 16 puestos de carga.

No obstante, un hallazgo crítico del estudio es que alcanzar niveles de servicio óptimos exige aceptar una ociosidad estructural (PTO) del orden del 58% al 61%. Este margen no constituye un desperdicio, sino la capacidad requerida para absorber la variabilidad estocástica de los arribos y sostener un desempeño eficiente del sistema. En términos de implementación, este resultado también supone desafíos relevantes para su adopción en CABA, tanto por la necesidad de desplegar múltiples nodos con restricciones físicas y de potencia, como por su impacto potencial sobre la viabilidad económica del operador.

En conclusión, el estudio evidencia que la transición hacia la movilidad eléctrica en Buenos Aires requiere una planificación de infraestructura basada en criterios de capacidad sistémica y no únicamente en la incorporación incremental de cargadores. Los resultados muestran que la eficiencia operativa y la calidad de servicio dependen de alcanzar una escala de despliegue capaz de absorber la demanda estocástica sin degradar la experiencia del usuario. Bajo esta perspectiva, la expansión de la red de carga deja de ser un problema puramente tecnológico para convertirse en un desafío integral de planificación urbana, energética y económica.

Futuras extensiones de este modelo podrían integrar costos tarifarios por minuto de carga y penalidades económicas por usuario perdido para afinar aún más el punto de equilibrio financiero de esta red distribuida.

Agradecimientos

Queremos agradecer al docente de la asignatura de Simulación Ing. David Carlos Mammana por el acompañamiento académico y las herramientas metodológicas brindadas durante la cursada, las cuales resultaron fundamentales para el desarrollo y análisis del presente trabajo de simulación.

Referencias

- [1] [Python Colab](#)
- [2] [Information-Driven EV Admission in Charging Station Considering User Impatience to Improve QoS and Station Utilization](#)
- [3] [EV Charging Station Usage of California City](#)
- [4] [Edenor-Cuadro Tarifario Mayo 2026](#)
- [5] [¿Cuánta energía consume un cargador de coche eléctrico al mes?](#)

Datos de contacto

Agustin Carlana Rivero. Universidad Tecnológica Nacional. acarlanarivero@frba.utn.edu.ar
Luca Manuel Loglen. Universidad Tecnológica Nacional. lloglen@frba.utn.edu.ar
Juan Ignacio Millan. Universidad Tecnológica Nacional. jmillan@frba.utn.edu.ar
Carlos Daniel Ojeda Cabrera. Universidad Tecnológica Nacional. cojedacabrera@frba.utn.edu.ar